



STUDY BUILD

LEARN • BUILD • APPLY

PROJECT 02

CUSTOMER ANALYTICS

From Data to Better Decisions

Analyze customer behavior, explore key patterns, and generate actionable insights to grow your e-commerce business.



Understand Customers

Demographics, behavior and preferences



Explore & Visualize

Powerful dashboards and insightful visualizations



Actionable Strategies

Data-driven recommendations to increase sales



Smarter Decisions

Turn data into smarter business actions



Prepared by

Atefe Asadi



2026

درباره این پروژه

در این پروژه شما نقش یک تحلیلگر داده تازه‌کار را در یک فروشگاه اینترنتی بر عهده دارید. مدیر شرکت به یک گزارش آماری ساده نیاز ندارد؛ او می‌خواهد بداند داده‌ها چه تصمیمی را پیشنهاد می‌کنند. بنابراین در هر بخش ابتدا یک درخواست واقعی مدیریتی مطرح می‌شود، سپس داده‌های لازم، نمودار مناسب، کد کامل پایتون، توضیح اجزای کد و خروجی تحلیلی مورد انتظار ارائه می‌شود.

نکته مهم

کدهای ارائه‌شده در این پروژه صرفاً به عنوان نمونه و برای درک بهتر روند حل مسئله آورده شده‌اند.

- لطفاً پیش از استفاده، صحت و درستی کدها را بررسی و در صورت نیاز اصلاح کنید.
- استفاده از این کدها الزامی نیست و شما می‌توانید با هر زبان برنامه‌نویسی، کتابخانه یا روشی که مناسب می‌دانید، پروژه را انجام دهید.
- هدف اصلی این پروژه، درک صورت مسئله، انتخاب روش مناسب و ارائه تحلیل صحیح از داده‌ها است؛ نه استفاده از یک کد یا ابزار خاص.

توجه: کیفیت تحلیل، استدلال و تفسیر نتایج، نسبت به نوع زبان برنامه‌نویسی یا ابزار مورد استفاده، از اهمیت بیشتری برخوردار است.

ساختار دیتاست

معنا	نام ستون
customer_id	شناسه یکتای مشتری
first_name	نام مشتری
gender	جنسیت
age	سن
city	شهر
province	استان
signup_date	تاریخ ثبت‌نام
membership_tier	سطح عضویت
purchase_count	تعداد خریدهای مشتری
avg_order_value	میانگین مبلغ هر سفارش
total_spending	مجموع مبلغ خرید مشتری
last_purchase_days	تعداد روز گذشته از آخرین خرید
payment_method	روش پرداخت
device	دستگاه مورد استفاده

استفاده از تخفیف	discount_used
تعداد کالاهای مرجوع شده	returned_items
امتیاز رضایت مشتری	satisfaction_score

آماده‌سازی اولیه و کنترل فایل

- در ابتدای پروژه، فایل Excel را در کنار فایل Notebook قرار دهید و این بخش از کد را اجرا کنید.
- این مرحله به صورت خودکار اقدامات زیر را انجام می‌دهد:
- وجود ستون‌های ضروری و مورد نیاز پروژه را کنترل می‌کند.
- ستون تاریخ ثبت نام را به فرمت استاندارد تاریخ (DateTime) تبدیل می‌کند.
- متغیرهای عددی را به نوع داده مناسب تبدیل می‌کند تا برای تحلیل، مصورسازی و مدل‌سازی آماده باشند.
- اجرای این بخش باعث می‌شود داده‌ها قبل از شروع فرآیند پاک‌سازی و تحلیل، از نظر ساختار و نوع داده‌ها بررسی و آماده شوند.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from pathlib import Path

df = pd.read_excel(FILE_PATH)

required_columns = [
    "customer_id", "first_name", "gender", "age", "city", "province",
    "signup_date", "membership_tier", "purchase_count", "avg_order_value",
    "total_spending", "last_purchase_days", "payment_method", "device",
    "discount_used", "returned_items", "satisfaction_score"
]

missing_columns = [col for col in required_columns if col not in df.columns]
if missing_columns:
    raise ValueError(f"این ستون‌ها در فایل وجود ندارند: {missing_columns}")

df["signup_date"] = pd.to_datetime(df["signup_date"], errors="coerce")

numeric_columns = [
    "age", "purchase_count", "avg_order_value", "total_spending",
    "last_purchase_days", "returned_items", "satisfaction_score"
]

for col in numeric_columns:
    df[col] = pd.to_numeric(df[col], errors="coerce")
```

```
text_columns = [
    "first_name", "gender", "city", "province", "membership_tier",
    "payment_method", "device", "discount_used"
]

for col in text_columns:
    df[col] = df[col].astype("string").str.strip()

print("ابعاد دیتاست:", df.shape)
print("تعداد رکوردهای تکراری:", df.duplicated().sum())
print("مقادیر گمشده هر ستون:")
print(df.isna().sum().sort_values(ascending=False))

display(df.head())
```

بخش کد	کاربرد و دلیل استفاده
برای خواندن فایل اکسل، گروه‌بندی، محاسبه pandas کتابخانه شاخص‌ها و ساخت جدول‌های تحلیلی استفاده می‌شود.	import pandas as pd
برای محاسبات عددی و مدیریت مقادیر ویژه استفاده می‌شود.	import numpy as np
برای رسم نمودارها استفاده می‌شود.	import matplotlib.pyplot as plt
مسیر فایل را به صورت قابل کنترل تعریف می‌کند.	Path("customer_data.xlsx")
قبل از خواندن فایل بررسی می‌کند که فایل واقعاً وجود دارد.	FILE_PATH.exists()
تبدیل می‌کند DataFrame را به Excel فایل	pd.read_excel(...)
فهرست دقیق ستون‌هایی است که پروژه بر اساس آن‌ها طراحی شده است.	required_columns
هر ستون لازم که در فایل نباشد شناسایی می‌شود تا تحلیل اشتباه ادامه پیدا نکند.	missing_columns
تاریخ‌های معتبر را تبدیل می‌کند و مقادیر نامعتبر را به مقدار گمشده تبدیل می‌کند.	pd.to_datetime(..., errors="coerce")
ستون‌های عددی را به عدد تبدیل می‌کند؛ مقادیر غیرقابل تبدیل گمشده می‌شوند.	pd.to_numeric(..., errors="coerce")
فاصله‌های اضافه ابتدا و انتهای متن‌ها را حذف می‌کند.	.astype("string").str.strip()
تعداد مقادیر گمشده هر ستون را نشان می‌دهد.	df.isna().sum()

پیش از ادامه پروژه

پیش از شروع تحلیل، داده‌ها را از نظر کیفیت بررسی کنید.

اگر مقادیر گمشده (Missing Values) مشاهده کردید، روش مدیریت آن‌ها را به‌طور کامل در فایل README.md توضیح دهید.

اگر رکوردهای تکراری (Duplicate Records) وجود داشت، نحوه شناسایی و تصمیم خود برای حذف یا نگهداری آن‌ها را در README.md مستند کنید.

هرگونه تغییر در نوع داده‌ها، اصلاح مقادیر غیرمنطقی یا پاک‌سازی داده‌ها نیز باید در فایل README.md ثبت شود.

سؤال ۱ - مشتریان اصلی فروشگاه چه کسانی هستند؟

درخواست مدیرعامل

پیش از طراحی کمپین تبلیغاتی، می‌خواهم تصویری روشن از مشتریان فعلی داشته باشم. گروه‌های سنی، جنسیت، سطح عضویت، دستگاه مورد استفاده و روش پرداخت را بررسی کنید و مشخص کنید مشتری غالب فروشگاه چه ویژگی‌هایی دارد.

ستون‌های مورد استفاده

- gender
- age
- membership_tier
- device
- payment_method

نمودارهای مورد انتظار

- نمودار میله‌ای تعداد مشتریان در هر گروه سنی
- نمودار میله‌ای توزیع سطح عضویت
- نمودار میله‌ای دستگاه مورد استفاده
- نمودار میله‌ای روش پرداخت

سؤال ۱: شناخت ویژگی‌های مشتریان

```
analysis_df = df.dropna(
    subset=["gender", "age", "membership_tier", "device", "payment_method"]
).copy()

age_bins = [0, 24, 34, 44, 54, 64, np.inf]
age_labels = ["زیر 25", "25-34", "35-44", "45-54", "55-64", "65 و بیشتر"]

analysis_df["age_group"] = pd.cut(
    analysis_df["age"],
    bins=age_bins,
    labels=age_labels,
```

```

include_lowest=True
)

profile_summary = {
    "تعداد مشتریان": analysis_df["customer_id"].nunique(),
    "میانگین سن": analysis_df["age"].mean(),
    "میانه سن": analysis_df["age"].median(),
    "رایج‌ترین جنسیت": analysis_df["gender"].mode().iloc[0],
    "رایج‌ترین سطح عضویت": analysis_df["membership_tier"].mode().iloc[0],
    "رایج‌ترین دستگاه": analysis_df["device"].mode().iloc[0],
    "رایج‌ترین روش پرداخت": analysis_df["payment_method"].mode().iloc[0]
}

profile_table = pd.Series(profile_summary, name="مقدار")
display(profile_table)

age_counts = analysis_df["age_group"].value_counts(sort=False)
age_counts.plot(kind="bar", figsize=(9, 5))
plt.title("تعداد مشتریان در گروه‌های سنی")
plt.xlabel("گروه سنی")
plt.ylabel("تعداد مشتری")
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()

for column, title in [
    ("membership_tier", "توزیع سطح عضویت مشتریان"),
    ("device", "دستگاه مورد استفاده مشتریان"),
    ("payment_method", "روش پرداخت مشتریان")
]:
    counts = analysis_df[column].value_counts().sort_values(ascending=True)
    counts.plot(kind="barh", figsize=(8, 4.5))
    plt.title(title)
    plt.xlabel("تعداد مشتری")
    plt.ylabel("")
    plt.tight_layout()
    plt.show()

```

فقط رکوردهایی را نگه می‌دارد که متغیرهای لازم این سؤال را دارند	dropna(subset=...)
سن پیوسته را به گروه‌های سنی قابل تفسیر برای مدیر تبدیل می‌کند	pd.cut(...)
تعداد مشتریان یکتا را محاسبه می‌کند	nunique()
مرکز توزیع سن را از دو دیدگاه میانگین و میانه نشان می‌دهد	mean() / median()
پرتکرارترین گروه را استخراج می‌کند	mode().iloc[0]
تعداد مشتریان هر دسته را محاسبه می‌کند	value_counts()
برای مقایسه تعداد گروه‌های سنی مناسب است	plot(kind="bar")
برای دسته‌هایی که نام نسبتاً بلند دارند خوانایی بیشتری ایجاد می‌کند	plot(kind="barh")
از بریده شدن عنوان‌ها و برچسب‌های نمودار جلوگیری می‌کند	tight_layout()

خروجی تحلیلی مورد انتظار

- یک جدول خلاصه از ویژگی‌های غالب مشتریان
- چهار نمودار واضح و دارای عنوان و برچسب محور
- یک پاراگراف که پرسونای غالب مشتری را فقط بر اساس داده تعریف کند

از این نمودارها چه تحلیلی می‌کنید؟

کدام گروه سنی بزرگ‌تر است؟ مشتریان بیشتر در چه سطح عضویتی قرار دارند؟ کدام دستگاه و روش پرداخت غالب است؟ آیا برای کمپین آینده باید پیام و کانال ارتباطی روی همین گروه غالب متمرکز شود یا گروه کم‌تعداد اما با ارزش‌تری نیز وجود دارد که در سؤالات بعدی باید بررسی شود؟

سؤال ۲ - کدام استان و شهر برای سرمایه‌گذاری تبلیغاتی مناسب‌تر است؟

درخواست مدیرعامل

بودجه تبلیغات محدود است. می‌خواهم بدانم کدام استان و کدام شهر هم مشتری بیشتری دارد و هم ارزش مالی بالاتری ایجاد کرده است. فقط بر اساس فروش بالا تصمیم نگیرید؛ تعداد مشتری، میانگین هزینه و رضایت را نیز در نظر بگیرید.

ستون‌های مورد استفاده

- province
- city
- customer_id
- total_spending
- purchase_count

- avg_order_value
- satisfaction_score

نمودارهای مورد انتظار

- نمودار میله‌ای افقی ۱۰ شهر برتر بر اساس مجموع خرید مشتریان
- نمودار پراکندگی مجموع خرید شهر در برابر میانگین رضایت؛ اندازه نقطه بر اساس تعداد مشتریان

سؤال ۲: انتخاب منطقه مناسب برای تبلیغات

```
location_df = df.dropna(
    subset=["province", "city", "customer_id", "total_spending", "satisfaction_score"]
).copy()

city_summary = (
    location_df.groupby(["province", "city"], as_index=False)
    .agg(
        customer_count=("customer_id", "nunique"),
        total_revenue=("total_spending", "sum"),
        avg_customer_spending=("total_spending", "mean"),
        avg_purchase_count=("purchase_count", "mean"),
        avg_order_value=("avg_order_value", "mean"),
        avg_satisfaction=("satisfaction_score", "mean")
    )
)

city_summary = city_summary[city_summary["customer_count"] >= 3].copy()

top_cities = city_summary.nlargest(10, "total_revenue").sort_values("total_revenue")
display(top_cities.sort_values("total_revenue", ascending=False))

labels = top_cities["province"] + " - " + top_cities["city"]
plt.figure(figsize=(10, 6))
plt.barh(labels, top_cities["total_revenue"])
plt.title("شهر برتر بر اساس مجموع خرید مشتریان ۱۰")
plt.xlabel("مجموع خرید مشتریان")
plt.ylabel("استان - شهر")
plt.tight_layout()
plt.show()

plt.figure(figsize=(9, 6))
```



```
plt.scatter(
    city_summary["total_revenue"],
    city_summary["avg_satisfaction"],
    s=city_summary["customer_count"] * 20,
    alpha=0.65
)

plt.title("ارزش مالی شهرها در برابر رضایت مشتری")
plt.xlabel("مجموع خرید مشتریان شهر")
plt.ylabel("میانگین رضایت")
plt.grid(alpha=0.25)
plt.tight_layout()
plt.show()

recommended_city = city_summary.sort_values(
    ["total_revenue", "avg_satisfaction", "customer_count"],
    ascending=[False, False, False]
).head(1)

display(recommended_city)
```

کاربرد و دلیل استفاده	بخش کد
groupby(["province", "city"])	مشتریان را در سطح ترکیبی استان و شهر گروه‌بندی می‌کند تا شهرهای هم‌نام اشتباه ادغام نشوند
.agg(...)	چند شاخص مدیریتی را هم‌زمان برای هر شهر محاسبه می‌کند
customer_count=(..., "nunique")	تعداد مشتریان یکتای هر شهر را می‌شمارد
total_revenue=(..., "sum")	مجموع مبلغ خرید تمام مشتریان هر شهر را محاسبه می‌کند
customer_count >= 3	شهرهایی با نمونه بسیار کوچک را حذف می‌کند تا یک یا دو مشتری نتیجه را منحرف نکنند. در گزارش باید این آستانه ذکر شود
nlargest(10, "total_revenue")	ده شهر با بیشترین مجموع خرید را انتخاب می‌کند
barh(...)	برای رتبه‌بندی شهرها و خواندن نام‌های بلند مناسب است
scatter(...)	رابطه ارزش مالی و رضایت را نشان می‌دهد
s=customer_count * 20	اندازه هر نقطه را متناسب با تعداد مشتریان شهر تعیین می‌کند
sort_values(...)	یک پیشنهاد اولیه بر اساس اولویت درآمد، سپس رضایت و تعداد مشتری تولید می‌کند؛ تصمیم نهایی باید تحلیلی باشد

خروجی تحلیلی مورد انتظار

- جدول شهرها شامل تعداد مشتری، مجموع خرید، میانگین خرید و رضایت
- نام یک شهر پیشنهادی و یک شهر جایگزین

- توضیح مزیت و ریسک انتخاب هر شهر

از این نمودارها چه تحلیلی می‌کنید؟

آیا شهر اول فقط به دلیل تعداد زیاد مشتریان در رتبه بالا قرار گرفته یا میانگین هزینه هر مشتری نیز بالاست؟ آیا رضایت آن شهر مناسب است؟ شهری که درآمد بالا ولی رضایت پایین دارد چه ریسکی برای تبلیغات دارد؟ تصمیم نهایی خود را با حداقل سه شاخص توجیه کنید.

سؤال ۳ - کدام مشتریان برای برنامه وفاداری اولویت دارند؟

درخواست مدیرعامل

برای برنامه وفاداری فقط می‌توانیم ۱۰ مشتری را انتخاب کنیم. مشتریانی را معرفی کنید که هم ارزش مالی بالایی دارند، هم خریدهای مکرر انجام داده‌اند و هم اخیراً فعال بوده‌اند. انتخاب صرفاً بر اساس سطح عضویت کافی نیست.

ستون‌های مورد استفاده

- customer_id
- first_name
- membership_tier
- purchase_count
- total_spending
- last_purchase_days
- satisfaction_score

نمودار مورد انتظار

- نمودار پراکندگی تعداد خرید در برابر مجموع خرید؛ مشتریان فعال‌تر با اندازه نقطه بزرگ‌تر نمایش داده شوند.

سؤال ۳: شناسایی مشتریان با ارزش و وفادار #

```
loyalty_df = df.dropna(
    subset=[
        "customer_id", "first_name", "purchase_count", "total_spending",
        "last_purchase_days", "satisfaction_score"
    ]
).copy()

for column in ["purchase_count", "total_spending", "satisfaction_score"]:
    minimum = loyalty_df[column].min()
    maximum = loyalty_df[column].max()
```

```

if maximum == minimum:
    loyalty_df[f"{column}_score"] = 1.0
else:
    loyalty_df[f"{column}_score"] = (
        loyalty_df[column] - minimum
    ) / (maximum - minimum)

recency_min = loyalty_df["last_purchase_days"].min()
recency_max = loyalty_df["last_purchase_days"].max()
if recency_max == recency_min:
    loyalty_df["recency_score"] = 1.0
else:
    loyalty_df["recency_score"] = 1 - (
        (loyalty_df["last_purchase_days"] - recency_min)
        / (recency_max - recency_min)
    )

loyalty_df["loyalty_score"] = (
    0.35 * loyalty_df["total_spending_score"]
    + 0.30 * loyalty_df["purchase_count_score"]
    + 0.20 * loyalty_df["recency_score"]
    + 0.15 * loyalty_df["satisfaction_score_score"]
)

top_loyal_customers = loyalty_df.nlargest(10, "loyalty_score")[[
    "customer_id", "first_name", "membership_tier", "purchase_count",
    "total_spending", "last_purchase_days", "satisfaction_score",
    "loyalty_score"
]]

display(top_loyal_customers)

plt.figure(figsize=(10, 6))
plt.scatter(
    loyalty_df["purchase_count"],
    loyalty_df["total_spending"],
    s=(loyalty_df["recency_score"] + 0.15) * 140,
    alpha=0.6
)
plt.scatter(

```

```

top_loyal_customers["purchase_count"],
top_loyal_customers["total_spending"],
s=180,
marker="*",
label="مشتری منتخب ۱۰"
)

plt.title("تعداد خرید در برابر مجموع خرید مشتریان")
plt.xlabel("تعداد خرید")
plt.ylabel("مجموع خرید")
plt.legend()
plt.grid(alpha=0.25)
plt.tight_layout()
plt.show()
    
```

بخش کد	کاربرد و دلیل استفاده
متغیرهایی با مقیاس متفاوت را به بازه صفر تا یک می‌برد تا بتوان آن‌ها را در یک امتیاز ترکیب کرد	min / max normalization
از تقسیم بر صفر جلوگیری می‌کند؛ این حالت زمانی رخ می‌دهد که همه مشتریان مقدار یکسان داشته باشند	if maximum == minimum
چون تعداد روز کمتر بهتر است، امتیاز تازگی را معکوس می‌کند تا مشتری تازه‌تر امتیاز بالاتری بگیرد	1 - normalized last_purchase_days
وزن‌های تحلیلی برای ارزش مالی، تکرار خرید، تازگی و رضایت هستند. این وزن‌ها باید در گزارش به‌عنوان فرض تحلیل ذکر شوند	0.35, 0.30, 0.20, 0.15
ده مشتری با بالاترین امتیاز ترکیبی را انتخاب می‌کند	nlargest(10, "loyalty_score")
مشتریان منتخب را روی نمودار با علامت متفاوت مشخص می‌کند	marker="*"

خروجی تحلیلی مورد انتظار

- جدول ۱۰ مشتری منتخب همراه با امتیاز وفاداری
- ذکر منطق وزن‌دهی و اینکه چرا این وزن‌ها انتخاب شده‌اند
- برای هر مشتری حداقل یک دلیل انتخاب، مانند هزینه بالا، تکرار خرید، تازگی یا رضایت

از این نمودار چه تحلیلی می‌کنید؟

آیا مشتریان منتخب هم‌زمان تعداد خرید و مجموع خرید بالایی دارند؟ آیا مشتری با مجموع خرید زیاد اما خرید بسیار قدیمی باید همچنان هدیه بگیرد؟ آیا سطح عضویت فعلی با امتیاز محاسبه‌شده سازگار است؟ موارد غیرعادی را توضیح دهید.

سؤال ۴ - کدام مشتریان باارزش در معرض غیرفعال شدن هستند؟

درخواست مدیرعامل

می‌خواهم مشتریانی را پیدا کنید که قبلاً برای شرکت ارزشمند بوده‌اند اما مدت زیادی از آخرین خریدشان گذشته است. هدف این است که پیش از از دست دادن کامل آن‌ها، یک کمپین بازگشت طراحی کنیم.

ستون‌های مورد استفاده

- customer_id
- first_name
- total_spending
- purchase_count
- last_purchase_days
- membership_tier
- satisfaction_score

نمودار مورد انتظار

- نمودار پراکندگی تعداد روز از آخرین خرید در برابر مجموع خرید؛ مشتریان در معرض خطر مشخص شوند.

سؤال ۴: شناسایی مشتریان باارزش در معرض غیرفعال شدن #

```
risk_df = df.dropna(
subset=[
"customer_id", "first_name", "total_spending",
"purchase_count", "last_purchase_days"
]
).copy()

spending_threshold = risk_df["total_spending"].quantile(0.75)
purchase_threshold = risk_df["purchase_count"].median()
inactivity_threshold = risk_df["last_purchase_days"].quantile(0.75)

risk_df["at_risk"] = (
(risk_df["total_spending"] >= spending_threshold)
& (risk_df["purchase_count"] >= purchase_threshold)
& (risk_df["last_purchase_days"] >= inactivity_threshold)
)

at_risk_customers = risk_df.loc[risk_df["at_risk"], ]
```

```
"customer_id", "first_name", "membership_tier", "purchase_count",
"total_spending", "last_purchase_days", "satisfaction_score"
]).sort_values(
["total_spending", "last_purchase_days"],
ascending=[False, False]
)

display(at_risk_customers)
print("تعداد مشتریان در معرض خطر:", len(at_risk_customers))

plt.figure(figsize=(10, 6))
plt.scatter(
risk_df.loc[~risk_df["at_risk"], "last_purchase_days"],
risk_df.loc[~risk_df["at_risk"], "total_spending"],
alpha=0.45,
label="سایر مشتریان"
)
plt.scatter(
risk_df.loc[risk_df["at_risk"], "last_purchase_days"],
risk_df.loc[risk_df["at_risk"], "total_spending"],
marker="X",
s=110,
label="مشتریان باارزش در معرض خطر"
)
plt.axvline(inactivity_threshold, linestyle="--", label="آستانه عدم فعالیت")
plt.axhline(spending_threshold, linestyle="--", label="آستانه ارزش مالی")
plt.title("شناسایی مشتریان باارزش در معرض غیرفعال شدن")
plt.xlabel("تعداد روز از آخرین خرید")
plt.ylabel("مجموع خرید مشتری")
plt.legend()
plt.grid(alpha=0.25)
plt.tight_layout()
plt.show()
```

بخش کد	کاربرد و دلیل استفاده
چارک سوم را محاسبه می‌کند؛ در اینجا مشتریان ۲۵ درصد بالای ارزش مالی و ۲۵ درصد بالای عدم فعالیت را مشخص می‌کند.	quantile(0.75)
آستانه تکرار خرید را بر اساس مقدار میانی داده تعیین می‌کند و نسبت به داده‌های پرت مقاوم‌تر از میانگین است.	median()

سه شرط را همزمان اعمال می‌کند؛ مشتری فقط زمانی در معرض خطر است که هر سه شرط برقرار باشند	&
آن‌ها درست است at_risk فقط مشتریانی را انتخاب می‌کند که پرچم	loc[...]
آستانه‌های تصمیم‌گیری را روی نمودار نشان می‌دهد تا منطق انتخاب قابل مشاهده باشد	axvline / axhline
مشتریان پرارزش‌تر و غیرفعال‌تر را در اولویت بررسی قرار می‌دهد	sort_values(...)

خروجی تحلیلی مورد انتظار

- «تعریف روشن و داده‌محور از «مشتری باارزش در معرض خطر»
- فهرست مشتریان هدف کمپین بازگشت
- پیشنهاد اقدام متفاوت برای مشتری ناراضی و مشتری راضی اما غیرفعال

از این نمودار چه تحلیلی می‌کنید؟

چند مشتری در ناحیه بالا-راست قرار گرفته‌اند؟ آیا رضایت آن‌ها پایین است یا صرفاً مدت زیادی خرید نکرده‌اند؟ کدام مشتریان باید فوراً هدف تماس یا پیشنهاد شخصی‌سازی شده قرار گیرند؟ محدودیت مهم: این دیتاست فقط فاصله از آخرین خرید را دارد و تاریخچه کامل سفارش‌ها را ندارد، بنابراین (ریزش قطعی). قابل اثبات نیست

سؤال ۵ - تخفیف، دستگاه و روش پرداخت با رفتار مشتری چه ارتباطی دارند؟

درخواست مدیرعامل

بین مدیران درباره تأثیر تخفیف اختلاف نظر وجود دارد. برخی معتقدند تخفیف خرید را افزایش می‌دهد و برخی نگران مرجوعی هستند. همچنین می‌خواهم بدانم مشتریان هر دستگاه و روش پرداخت چه ارزش و رضایتی دارند. یک مقایسه توصیفی انجام دهید و از ادعای علت و معلولی خودداری کنید.

ستون‌های مورد استفاده

- discount_used
- device
- payment_method
- total_spending
- purchase_count
- avg_order_value
- returned_items
- satisfaction_score

نمودارهای مورد انتظار

- نمودار میله‌ای میانگین مجموع خرید بر اساس استفاده از تخفیف
- نمودار میله‌ای میانگین تعداد مرجوعی بر اساس استفاده از تخفیف
- نمودار میله‌ای میانگین مجموع خرید بر اساس دستگاه
- نمودار میله‌ای میانگین مجموع خرید بر اساس روش پرداخت

سؤال ۵: مقایسه رفتار مشتری بر اساس تخفیف، دستگاه و روش پرداخت #

```
factor_df = df.dropna(
    subset=[
        "discount_used", "device", "payment_method", "total_spending",
        "purchase_count", "avg_order_value", "returned_items",
        "satisfaction_score"
    ]
).copy()

summary_by_discount = (
    factor_df.groupby("discount_used", as_index=False)
    .agg(
        customer_count=("customer_id", "nunique"),
        avg_total_spending=("total_spending", "mean"),
        avg_purchase_count=("purchase_count", "mean"),
        avg_order_value=("avg_order_value", "mean"),
        avg_returned_items=("returned_items", "mean"),
        avg_satisfaction=("satisfaction_score", "mean")
    )
)

display(summary_by_discount)

metrics = [
    ("avg_total_spending", "میانگین مجموع خرید بر اساس استفاده از تخفیف", "میانگین مجموع خرید"),
    ("avg_returned_items", "میانگین تعداد مرجوعی", "میانگین تعداد مرجوعی")
]

for metric, title, ylabel in metrics:
    summary_by_discount.plot(
        x="discount_used", y=metric, kind="bar", legend=False, figsize=(7, 4.5)
    )
    plt.title(title)
```

```
plt.xlabel("استفاده از تخفیف")
plt.ylabel(ylabel)
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()

for factor, title in [
    ("device", "میانگین مجموع خرید بر اساس دستگاه"),
    ("payment_method", "میانگین مجموع خرید بر اساس روش پرداخت")
]:
    factor_summary = (
        factor_df.groupby(factor)["total_spending"]
        .agg(["count", "mean"])
        .query("count >= 3")
        .sort_values("mean", ascending=True)
    )

    display(factor_summary)
    factor_summary["mean"].plot(kind="barh", figsize=(8, 4.5))
    plt.title(title)
    plt.xlabel("میانگین مجموع خرید مشتری")
    plt.ylabel("")
    plt.tight_layout()
    plt.show()
```

کاربرد و دلیل استفاده	بخش کد
groupby("discount_used")	مشتریان استفاده‌کننده و استفاده‌نکرده از تخفیف را مقایسه می‌کند
.agg(...)	شاخص‌های ارزش مالی، تکرار خرید، مبلغ سفارش، مرجوعی و رضایت را در هر گروه محاسبه می‌کند
for metric, title, ylabel in metrics	برای جلوگیری از تکرار کد، دو نمودار تخفیف را با یک حلقه رسم می‌کند
groupby(factor)["total_spending"]	برای هر دستگاه یا روش پرداخت، مجموع خرید مشتریان را گروه‌بندی می‌کند
agg(["count", "mean"])	هم تعداد مشاهدات هر دسته و هم میانگین را محاسبه می‌کند
query("count >= 3")	دسته‌های بسیار کم‌نمونه را از مقایسه اصلی کنار می‌گذارد
barh	مقایسه رتبه‌ای دستگاه‌ها و روش‌های پرداخت را خواناتر می‌کند

خروجی تحلیلی مورد انتظار

- جدول مقایسه مشتریان با تخفیف و بدون تخفیف
- مشخص کردن اینکه تخفیف با هزینه، تکرار خرید، مرجوعی و رضایت چه الگوی توصیفی دارد
- تعیین دستگاه و روش پرداختی که بیشترین میانگین ارزش مشتری را دارد
- «نوشتن صریح این جمله:» این تحلیل رابطه علت و معلولی را اثبات نمی‌کند

از این نمودارها چه تحلیلی می‌کنید؟

آیا مشتریان استفاده‌کننده از تخفیف هزینه بیشتری دارند؟ آیا هم‌زمان مرجوعی آن‌ها نیز بیشتر است؟ اختلاف مشاهده‌شده با چه تعداد مشتری به دست آمده است؟ کدام دستگاه یا روش پرداخت میانگین بالاتری دارد و آیا حجم نمونه آن برای تصمیم‌گیری مناسب است؟

سؤال ۶ - گزارش پنج دقیقه‌ای مدیرعامل را بسازید

درخواست مدیرعامل

من فقط پنج دقیقه برای مشاهده گزارش فرصت دارم. یک صفحه مدیریتی تهیه کنید که وضعیت کلی کسب‌وکار، مهم‌ترین فرصت و مهم‌ترین انتخاب کنید KPI ریسک مشتریان را نشان دهد. فقط سه نمودار و حداکثر شش

ستون‌های مورد استفاده

این بخش از خروجی سؤال‌های قبل استفاده می‌کند و می‌تواند از تمام ستون‌های دیتاست بهره ببرد.

خروجی تصویری مورد انتظار

- در قالب جدول خلاصه KPI شش
- سه نمودار منتخب از سؤال‌های قبل
- Evidence → Action → KPI سه پیشنهاد مدیریتی با ساختار

سؤال ۶: ساخت گزارش مدیریتی نهایی #

```
kpi_summary = pd.Series({
    "تعداد مشتریان یکتا": df["customer_id"].nunique(),
    "مجموع خرید مشتریان": df["total_spending"].sum(),
    "میانگین مجموع خرید هر مشتری": df["total_spending"].mean(),
    "میانگین تعداد خرید": df["purchase_count"].mean(),
    "میانگین رضایت": df["satisfaction_score"].mean(),
    "مجموع کالاهای مرجوع‌شده": df["returned_items"].sum()
}, name="مقدار")
```

```
display(kpi_summary)
```

```
# نمودار ۱: ۱۰ شهر برتر
chart1 = city_summary.nlargest(10, "total_revenue").sort_values("total_revenue")
chart1_labels = chart1["province"] + " - " + chart1["city"]
plt.figure(figsize=(10, 6))
plt.barh(chart1_labels, chart1["total_revenue"])
plt.title("شهر برتر بر اساس مجموع خرید ۱۰")
plt.xlabel("مجموع خرید مشتریان")
plt.tight_layout()
plt.show()

# نمودار ۲: مشتریان باارزش در معرض خطر
plt.figure(figsize=(10, 6))
plt.scatter(
    risk_df.loc[~risk_df["at_risk"], "last_purchase_days"],
    risk_df.loc[~risk_df["at_risk"], "total_spending"],
    alpha=0.4,
    label="سایر مشتریان"
)
plt.scatter(
    risk_df.loc[risk_df["at_risk"], "last_purchase_days"],
    risk_df.loc[risk_df["at_risk"], "total_spending"],
    marker="X", s=110, label="در معرض خطر"
)
plt.title("مشتریان باارزش در معرض غیرفعال شدن")
plt.xlabel("تعداد روز از آخرین خرید")
plt.ylabel("مجموع خرید")
plt.legend()
plt.tight_layout()
plt.show()

# نمودار ۳: مقایسه تخفیف
summary_by_discount.plot(
    x="discount_used",
    y=["avg_total_spending", "avg_returned_items"],
    kind="bar",
    figsize=(9, 5)
)
plt.title("مقایسه ارزش مالی و مرجوعی بر اساس استفاده از تخفیف")
plt.xlabel("استفاده از تخفیف")
```

```
plt.ylabel("میانگین")
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()

# ذخیره جدول‌های اصلی برای گزارش نهایی
with pd.ExcelWriter("customer_analytics_results.xlsx") as writer:
    kpi_summary.to_excel(writer, sheet_name="KPI")
    city_summary.to_excel(writer, sheet_name="City Analysis", index=False)
    top_loyal_customers.to_excel(writer, sheet_name="Top Loyal Customers", index=False)
    at_risk_customers.to_excel(writer, sheet_name="At Risk Customers", index=False)
    summary_by_discount.to_excel(writer, sheet_name="Discount Analysis", index=False)

print("ذخیره شد customer_analytics_results.xlsx فایل")
```

کاربرد و دلیل استفاده	بخش کد
pd.Series({...})	های اصلی را در یک جدول دو ستونی ساده و مناسب گزارش KPI مدیریت قرار می‌دهد.
df["customer_id"].nunique()	تعداد واقعی مشتریان یکتا را محاسبه می‌کند.
sum() / mean()	مجموع شاخص‌ها و میانگین عملکرد مشتریان را محاسبه می‌کند.
city_summary و risk_df استفاده از	به جای محاسبه دوباره، خروجی‌های معتبر سؤال‌های قبلی را بازاستفاده می‌کند.
pd.ExcelWriter(...)	ذخیره Excel چند جدول خروجی را در شیت‌های جداگانه یک فایل می‌کند.
to_excel(..., index=False)	در فایل خروجی pandas جدول را بدون ستون شماره‌گذاری می‌نویسد.

فایل‌های تحویلی پروژه

- فایل customer_analytics_username.ipynb با نام Notebook فایل
- فایل customer_analytics_results.xlsx فایل خروجی
- فایل داده پاک‌سازی شده مورد استفاده در تحلیل
- شامل مسئله، مراحل، یافته‌ها، محدودیت‌ها و پیشنهادها README.md فایل
- کوتاه شامل سه نمودار نهایی و سه پیشنهاد مدیریتی PDF حداکثر یک گزارش

README ساختار پیشنهادی

- Project Overview
- Dataset Description
- Data Quality Checks
- Business Questions
- Key Findings
- Business Recommendations
- Limitations

محدودیت‌های تحلیل (Analysis Limitations)

- در تفسیر نتایج، محدودیت‌های زیر را در نظر داشته باشید و در صورت لزوم در گزارش نهایی به آن‌ها اشاره کنید:
- هر ردیف نماینده‌ی خلاصه‌ای از وضعیت یک مشتری است و اطلاعات مربوط به تمام سفارش‌های ثبت‌شده در اختیار نیست؛ بنابراین امکان تحلیل جزئیات هر سفارش وجود ندارد.
- ستون `last_purchase_days` تنها تعداد روزهای سپری‌شده از آخرین خرید مشتری را نشان می‌دهد و اطلاعات کاملی از تاریخچه خرید و رفتار زمانی مشتری ارائه نمی‌کند.
- تحلیل مربوط به تخفیف‌ها (Discount) صرفاً بر اساس داده‌های مشاهده‌شده انجام می‌شود و نمی‌توان از آن رابطه علت و معلولی بین تخفیف و رفتار مشتری را نتیجه‌گیری کرد.
- ستون `returned_items` فقط تعداد اقلام مرجوع‌شده را نشان می‌دهد. از آنجا که تعداد کل اقلام خریداری‌شده برای هر مشتری در دسترس نیست، محاسبه نرخ واقعی مرجوعی (Return Rate) امکان‌پذیر نیست.
- اگر تعداد مشتریان در یک شهر، گروه یا دسته خاص کم باشد، میانگین‌ها و سایر شاخص‌های آماری ممکن است پایدار نباشند و نتایج آن‌ها باید با احتیاط تفسیر شوند.
- توجه: نتایج این پروژه بر اساس داده‌های موجود استخراج شده‌اند و هرگونه نتیجه‌گیری باید با در نظر گرفتن محدودیت‌های فوق انجام شود.

چک‌لیست نهایی تحلیلگر

- آیا همه نمودارها عنوان و نام محور دارند؟
- آیا قبل از هر نتیجه، جدول یا عدد پشتیبان ارائه شده است؟
- آیا بین همبستگی و رابطه علت و معلولی تفاوت گذاشته شده است؟
- آیا آستانه‌ها و وزن‌های اختیاری تحلیل توضیح داده شده‌اند؟
- آیا پیشنهادها عملی، قابل اندازه‌گیری و مرتبط با یافته‌ها هستند؟
- آیا محدودیت‌های دیتاست صادقانه گزارش شده‌اند؟